



南京大學

本科畢業論文

院 系 智能科学与技术学院

专 业 智能科学与技术

题 目 基于强化学习的

机械臂操作算法研究

年 级 2022 学 号 221900027

学生姓名 刘辰亮

指导教师 邴振山 职 称 副教授

提交日期 2026 年 6 月 7 日



南京大学本科毕业论文（设计）

诚信承诺书

本人郑重承诺：所呈交的毕业论文（设计）（题目：基于强化学习的机械臂操作算法研究）是在指导教师的指导下严格按照学校和学院有关规定由本人独立完成的。本毕业论文（设计）中引用他人观点及参考资源的内容均已标注引用，如出现侵犯他人知识产权的行为，由本人承担相应法律责任。本人承诺不存在抄袭、伪造、篡改、代写、买卖毕业论文（设计）等违纪行为。

作者签名：刘辰亮

学号：221900027

日期：2026年6月7日

南京大学本科生毕业论文（设计、作品）中文摘要

题目：基于强化学习的机械臂操作算法研究

院系：智能科学与技术学院

专业：智能科学与技术

本科生姓名：刘辰亮

指导教师（姓名、职称）：邴振山 副教授

摘要：

机械臂在工业制造、仓储物流、服务机器人和科研实验等场景中具有广泛的应用。传统机械臂的操作方法通常依靠人工设计的轨迹、精确建模和任务级规则，在结构化环境中具有较好的可靠性。但是，当物体位置、接触状态和执行误差发生变化时，人工规则常常需要反复调整参数。强化学习通过试错交互，学习状态到动作的映射，为机械臂在复杂接触任务中的自适应控制提供了新的技术路线。

本文围绕机械臂抓取并抬起桌面物体这一典型操作任务，基于 MuJoCo 物理引擎和 robosuite 机器人仿真平台，构建了 Franka 机械臂的强化学习训练流程。系统用低维状态观测来表示机械臂末端位置、夹爪开合量、物体位姿以及末端到物体的相对位置；系统采用操作空间位置控制作为底层控制接口，使用 Soft Actor-Critic (SAC) 算法进行连续动作策略学习。针对仿真训练得到的策略的不稳定性，具体表现为可能出现成功抓取并抬起物体到一定高度后继续上抬和随机摆动的问题，本文进一步设计了稳定抬升目标、工作空间约束、动作裁剪、后抬升运动惩罚和连续稳定保持判据，让成功指标从单纯的抬离桌面转变为抬起少量高度并保持稳定。

实验结果表明，所设计出来的方法可以在仿真环境里学习到有效的桌面物体抬升策略。与只使用原始抬升成功条件的训练方式进行比较，引入稳定保持判据以后，评估指标能够更加准确地对短暂抬起、受控抬起和稳定保持这三类行为进行区分。在此基础上，本文进一步完成了基于 Franka Research 3 机械臂、RealSense 相机和 ArUco 视觉定位的 sim-to-real 验证，说明低维位姿策略经过坐标统一、动作限幅和安全裁剪后可以迁移到真实机械臂执行。

关键词：强化学习；机械臂操作；Soft Actor-Critic；MuJoCo；robosuite

南京大学本科生毕业论文（设计、作品）英文摘要

THESIS: Research on Robotic Manipulation Algorithms Based on Reinforcement Learning

DEPARTMENT: School of Intelligence Science and Technology

SPECIALIZATION: Intelligence Science and Technology

UNDERGRADUATE: Liu Chenliang

MENTOR: Associate Professor Bing Zhenshan

ABSTRACT:

Robotic manipulators are widely used in industrial manufacturing, warehouse logistics, service robotics, and scientific research. Conventional robotic manipulation methods typically rely on manually designed trajectories, accurate system modeling, and task-level rules, which can achieve reliable performance in structured environments. However, when object positions, contact conditions, or execution errors vary, these manually designed rules often require repeated parameter tuning. Reinforcement learning learns state-to-action mappings through trial-and-error interactions, thereby providing a promising approach for adaptive control of robotic manipulators in complex contact-rich tasks.

This paper investigates a representative manipulation task in which a robotic arm grasps and lifts an object from a tabletop. Based on the MuJoCo physics engine and the robosuite robotic simulation platform, a reinforcement learning training pipeline is developed for the Franka robotic arm. The system uses low-dimensional state observations to represent the end-effector position, gripper opening state, object pose, and the relative position between the end effector and the object. Operational space position control is adopted as the low-level control interface, and the Soft Actor-Critic (SAC) algorithm is used to learn a continuous control policy. To address the instability of the policy trained in simulation, which may continue moving upward or exhibit random oscillatory motions after successfully grasping and lifting the object to a certain height, this paper further designs a stable lifting target, workspace constraints, action clipping, a post-lifting motion penalty, and a continuous stable-holding criterion. As a result, the

success criterion is refined from simply lifting the object off the tabletop to lifting the object by a small height and maintaining stability.

The experimental results show that the proposed method can learn an effective tabletop object-lifting policy in simulation. Compared with the training strategy that only uses the original lifting success condition, the introduction of the stable-holding criterion enables the evaluation metrics to distinguish more accurately among three types of behaviors: transient lifting, controlled lifting, and stable holding. On this basis, this paper further conducts sim-to-real validation using a Franka Research 3 robotic arm, a RealSense camera, and ArUco-based visual localization. The results indicate that the low-dimensional pose-based policy can be deployed on a real robotic arm after coordinate-frame alignment, action range limiting, and safety clipping.

KEYWORDS: Reinforcement Learning; Robotic Manipulation; Soft Actor-Critic; MuJoCo; robosuite

目 录

目 录	IV
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.3 本文主要工作	4
1.4 论文结构	5
第二章 相关理论基础	6
2.1 机械臂运动控制基础	6
2.2 马尔可夫决策过程	7
2.3 Soft Actor-Critic (SAC) 算法	10
2.4 手眼标定	12
第三章 系统设计与实现	14
3.1 总体架构	14
3.2 仿真环境与状态动作空间	16
3.3 训练流程与实验记录	18
3.4 稳定抬升控制方法	20
3.4.1 问题分析	20
3.4.2 工作空间约束	21
3.4.3 稳定抬升判据	21
3.4.4 奖励函数改进	21
3.4.5 评价指标设计	22
3.5 真实平台部署设计	22

3.5.1	真实系统组成	22
3.5.2	视觉定位与坐标变换	24
3.5.3	真实观测构造	24
3.5.4	动作执行与安全裁剪	25
第四章	实验结果与分析	27
4.1	仿真实验设置	27
4.2	仿真训练收敛性分析	27
4.3	任务成功率分析	28
4.4	仿真可视化行为分析	30
4.5	真实机械臂验证结果	32
4.6	真实机械臂安全措施	33
第五章	总结与展望	34
5.1	全文总结	34
5.2	不足与展望	34
	参考文献	36
	致 谢	39
	附录 A 缩略语说明	40

第一章 绪论

1.1 研究背景与意义

机械臂是机器人系统中最重要执行机构之一。与移动机器人主要解决空间移动问题不同，机械臂需要在有限工作空间内完成抓取、搬运、装配、插孔、开门等直接作用于外部物体的操作任务。这类任务不仅涉及机械臂自身的运动学和动力学，还涉及夹爪与物体、物体与环境之间的接触关系。因此，机械臂操作算法既需要保证轨迹的可达性和安全性，也需要处理接触过程中的不确定性。随着智能制造、柔性生产、智慧物流和服务机器人需求的增长，机械臂已经不再只面对固定工位上的重复轨迹，而是需要在目标位置变化、物体形状多样、环境局部未知和接触状态不确定的条件下完成任务。




图 1-1 机械臂在工业生产线上

在传统控制框架中，机械臂的操作一般由感知、规划和控制等模块构成。系统会首先估计目标物体的位置和姿态，然后通过运动规划器生成无碰撞轨迹，最后由底层控制器对轨迹进行跟踪。这类方法结构清晰、可解释性也比较好，在工业生产线上得到了广泛的应用。然而，传统方法往往依赖较为准确的物体模型、环境地图和机械臂标定结果。当物体发生遮挡、堆叠、轻微滑移或者接触状态改变的情况时，离线规划得到的轨迹可能就不再适用了。视觉伺服研究着重利用

视觉反馈来形成闭环控制^[1-2]，采样式路径规划研究则为高维机械臂空间中的可行路径搜索提供了经典工具^[3-4]。但是，在动态目标、障碍物、密集堆叠物体和服务场景长序列任务中，系统仍然需要更强的自主感知与决策能力。

强化学习给机械臂操作提供了一种不同的建模思路。核心思想是把机器人看作一个智能体，通过与环境进行交互来获得奖励信号，并且优化能让长期收益达到最大的策略。近年来，深度强化学习在机器人控制、灵巧手操作等任务中取得了显著的进展^[5-6]。对于机械臂而言，强化学习可以直接从状态和奖励中学习控制策略，减少对人工轨迹设计的依赖，还能让策略在大量的仿真交互中逐渐获得像“接近目标、形成接触、闭合夹爪、抬升物体、保持稳定”这样的连续操作能力。与单纯的路径规划相比，强化学习更适合描述动作和接触反馈之间的闭环关系；与纯规则控制相比，强化学习能够在一定范围内适应初始状态扰动和物体位姿变化。

与此同时，强化学习在机械臂任务中的应用仍面临训练样本需求大、奖励设计困难、训练过程不稳定、仿真到真实迁移存在差异等问题。相关研究常通过视觉伺服、路径规划、推抓协同、迁移学习和任务知识建模等方式增强策略学习能力。例如，视觉伺服可以提高机械臂对目标相对位姿变化的响应能力；路径规划可以为强化学习提供安全引导；推抓协同可以解决密集堆叠环境中无可行抓取位姿的问题^[7]；迁移学习、多任务基准和目标条件学习可以减少新任务的训练时间并提高泛化能力^[8-9]。这些工作表明，机械臂强化学习研究的重点正在从“能否完成任务”进一步转向“是否高效、安全、稳定并可迁移地完成任务”。

本文以桌面物体抬升任务为研究对象。该任务包含机械臂接近、对准、闭合夹爪、接触抓取、抬升和稳定保持等操作环节，是研究机械臂强化学习控制的典型任务。本文先在仿真平台对策略进行训练，并且重点关注策略行为的稳定性，而不是只关注能否短暂抬起物体；随后将训练得到的策略迁移到 Franka Research 3 真实机械臂平台。该任务可以用较低的系统复杂度验证强化学习在连续机械臂控制中的有效性，并且抬升后的稳定保持要求与真实机械臂部署中的安全需求紧密相关。通过完成从仿真训练到真实机械臂验证的闭环流程，本文进一步检验了低维位姿策略在真实平台上的可迁移性和工程实现可行性。

1.2 国内外研究现状

强化学习的基本理论可以追溯到马尔可夫决策过程和动态规划。Sutton 和 Barto 系统总结了强化学习中的价值函数、策略优化、时序差分学习等基础方法^[10]。随着深度神经网络不断发展,深度强化学习可以处理高维状态和复杂函数逼近问题。Deep Q-Network(DQN)使用深度网络来近似动作价值函数,在离散动作控制方面取得了突破^[5]。连续控制任务则更适合使用策略梯度、Actor-Critic 等方法。机械臂操作属于典型的连续控制问题,策略输出通常对应末端位移、末端速度、关节速度和夹爪开合量,因此需要能够处理连续动作空间的强化学习算法。

从算法角度看, Proximal Policy Optimization (PPO)^[11]、Deep Deterministic Policy Gradient (DDPG)^[12]、Twin Delayed Deep Deterministic Policy Gradient (TD3) 和 Soft Actor-Critic (SAC) 等方法都被广泛应用于连续控制任务。其中, SAC 通过最大熵目标鼓励策略保持一定的随机性,能够提高探索能力和训练稳定性^[13]。因为机械臂操作任务经常存在稀疏成功信号和复杂接触状态,所以 SAC 的离策略样本复用能力可以提高训练效率。最近几年,针对机器人操作的研究进一步关注于价值估计偏差、样本效率和多任务泛化问题。例如, Hindsight Experience Replay 通过重新标记目标缓解了稀疏奖励问题^[8], Meta-World 等基准推动了多任务和元强化学习在机器人操作中的系统评估^[9]。这说明在机械臂操作问题中,单一强化学习算法往往需要结合任务结构和先验知识进行改进。

在感知与抓取方面,视觉信息是机械臂在非结构化环境中进行物体操作的重要来源。早期的视觉伺服研究系统探讨了图像特征、相机模型和机械臂控制之间的关系,这为基于视觉反馈的闭环操作奠定了基础^[1-2]。随着深度学习发展, You Only Look Once (YOLO) 等目标检测方法显著提升了实时物体识别能力^[14], Lenz 等人使用深度学习检测机械臂的抓取位姿^[15], Morrison 等人提出的 Generative Grasping Convolutional Neural Network (GG-CNN) 能够从深度图中实时生成抓取姿态^[16]。这类研究表明,强化学习不能孤立地替代传统控制,而是应与视觉感知、抓取位姿估计、坐标变换以及运动学建模共同构成闭环操作系统。

从路径规划和安全角度看,机械臂在复杂环境中不仅要接近目标,还必须避免碰撞。Rapidly-exploring Random Tree (RRT) 和 RRT-Connect 可以在高维空

间中快速搜索可行的路径^[3,17]，RRT* 还进一步给出了渐近最优性分析^[4]。不过，采样式规划对环境建模和碰撞检测的依赖比较强，在动态接触任务中仍然需要和反馈控制或学习方法相结合。DQN、Double DQN 和优先经验回放等深度强化学习方法则从价值学习角度提升了智能体在复杂状态空间中的决策能力^[5,18-19]。这类研究对本文具有启发意义：机械臂强化学习的奖励不能只看是否到达终点，还要关注运动过程是否平稳、安全和可执行。

从操作复杂物体的角度出发，仅仅依靠直接抓取不能满足所有场景的需求。在生活场景和仓储环境中，物体经常是密集堆叠或者相互遮挡的，机械臂可能无法直接找到合适的抓取位姿。QT-Opt 利用大规模自监督数据来训练机械臂的抓取策略，显示出了深度强化学习在真实机械臂抓取中的潜力^[20]；Zeng 等人提出了视觉推动和抓取协同学习的方法，让机械臂能够通过推动来改变场景结构，然后再执行更可靠的抓取^[7]。这些研究表明，机械臂操作算法的发展趋势是从单一动作扩展到多技能协同，并且逐渐重视泛化性、样本效率和真实环境中的可用性。

机器人强化学习高度依赖仿真环境。MuJoCo 是常用的机器人动力学仿真引擎，能够提供高效的刚体动力学和接触求解能力^[21]。robosuite 在 MuJoCo 之上封装了机械臂模型、夹爪模型、桌面操作任务、控制器和传感器接口，为可复现实验提供了便利^[22]。本文采用 robosuite 中的 Lift 任务作为基础环境，并在其外部构建符合 Gymnasium 接口的强化学习训练包装器。面向单物体抬升任务训练强化学习控制策略，使机械臂在完成接近和夹取后，能够将物体抬升到目标高度附近并保持静止，保证了强化学习策略从仿真走向真实机械臂时的稳定性与安全性。

1.3 本文主要工作

本文的主要工作包括以下几个方面：

1. 基于 robosuite 和 MuJoCo 搭建机械臂桌面立方体物块抬升仿真环境，选用 Franka Research 3 机械臂和操作空间位置控制器作为实验平台。
2. 设计低维的状态空间，把末端位置、夹爪开合量、立方体物块位置、立方体物块四元数以及末端到立方体物块的相对位置组合起来作为策略的输入，

可以降低视觉训练的复杂度。

3. 使用 SAC 算法训练连续动作控制策略，并且通过 TensorBoard 记录奖励、成功率、回合长度等指标。
4. 针对训练策略中出现的过度上抬和随机摆动问题，设计了稳定抬升奖励、动作惩罚、速度惩罚和连续保持成功判据。
5. 面向 Franka Research 3 真实机械臂完成 sim-to-real 验证。真实系统使用 RealSense 相机和 ArUco 标记估计立方体物块位姿，通过手眼标定将相机坐标系下的物块位姿转换到机器人基坐标系，并构造与仿真一致的低维观测，加载训练得到的最优策略模型进行推理。真实执行阶段将策略输出的归一化位置动作转换为受限的笛卡尔线性位移，并根据策略第四维动作控制 Franka Hand 闭合，从而完成真实平台上的接近、夹取和抬升验证。

1.4 论文结构

本文共分为六章。第一章介绍研究背景、研究现状和主要工作。第二章介绍机械臂控制与强化学习相关理论。第三章描述系统环境、状态动作空间、训练流程、稳定抬升控制方法以及真实平台部署设计。第四章给出实验设计与结果分析。第五章总结全文。

第二章 相关理论基础

2.1 机械臂运动控制基础

机械臂通常由多个转动或移动关节串联组成。对于串联机械臂而言，关节空间描述的是各关节的位置、速度和力矩，任务空间描述的是末端执行器在三维空间中的位置和姿态。机械臂控制算法的核心问题之一，就是建立关节空间与任务空间之间的映射关系，并在满足关节限位、速度限制和碰撞约束的条件下，使末端执行器完成预期操作。

设机械臂关节变量为

$$\mathbf{q} = [q_1, q_2, \dots, q_n]^T, \quad (2-1)$$

其中 n 为自由度数量， q_i 表示第 i 个关节的关节变量。末端执行器在笛卡尔空间中的位姿可表示为

$$\mathbf{x} = f(\mathbf{q}), \quad (2-2)$$

其中 $\mathbf{q}$ 为机械臂关节状态向量， $f(\cdot)$ 为正运动学映射。末端速度与关节速度之间满足

$$\dot{\mathbf{x}} = \mathbf{J}(\mathbf{q})\dot{\mathbf{q}}, \quad (2-3)$$

其中 $\dot{\mathbf{q}}$ 为关节速度向量， $\mathbf{J}(\mathbf{q})$ 为雅可比矩阵。

雅可比矩阵不仅用于速度映射，也用于把任务空间误差转换为关节空间控制量。当机械臂接近奇异位形时，雅可比矩阵可能出现秩亏，导致某些方向上的末端速度难以通过有限关节速度实现。因此，在真实机械臂控制中，通常需要结合速度限制、阻尼伪逆、关节限位规避和工作空间约束等策略，避免机械臂进入不稳定或不可控区域。

机械臂动力学可用如下形式表示：

$$\mathbf{M}(q)\ddot{q} + \mathbf{C}(q, \dot{q})\dot{q} + \mathbf{g}(q) = \boldsymbol{\tau} + \mathbf{J}^T(q)\mathbf{F}, \quad (2-4)$$

其中 $\mathbf{M}$ 是惯性矩阵， $\ddot{q}$ 为关节加速度向量， $\mathbf{C}$ 是科氏力和离心力项， $\mathbf{g}$ 是重力项， $\boldsymbol{\tau}$ 是关节力矩， $\mathbf{F}$ 是末端外力。在包含接触的操作任务里，末端力和物体接触状态会对机械臂运动产生影响，因此纯位置轨迹跟踪通常无法描述完整任务。

在桌面抓取任务中，虽然直接对关节角度进行控制是可行的，但是策略需要学习从任务空间目标到关节空间动作的复杂映射。为了降低学习难度，本文采用操作空间控制（Operational Space Control, OSC）作为底层控制方式^[23]。在这种方式下，强化学习策略会输出末端执行器在三维空间中的小位移，底层控制器会把末端目标转换为关节力矩或者关节控制命令。这样可以让策略更直接地关注“末端应该向哪里移动”。

操作空间控制通常在任务空间中定义末端误差：

$$\mathbf{e}_x = \mathbf{x}_d - \mathbf{x}, \quad (2-5)$$

其中 $\mathbf{x}_d$ 为期望末端位姿， $\mathbf{x}$ 为当前末端位姿。控制器根据末端误差、末端速度以及机械臂动力学模型生成关节控制量。对于本文使用的 OSC_POSITION 控制器，策略不直接输出姿态变化，而是输出末端位置增量和夹爪动作。该设计减少了动作空间维度，有利于在立方体物块抬升任务中提高训练效率。

2.2 马尔可夫决策过程

强化学习关注智能体如何通过与环境交互来学习决策策略。在机械臂操作任务中，机械臂及其控制策略可视为智能体，仿真或真实操作场景可视为环境。在每一个控制时刻，智能体可以根据当前的观测来选择动作，当动作作用于环境之后，环境的状态会发生变化，并且会返回奖励信号。奖励能够对当前动作在任务目标中的贡献进行评价，智能体则可以根据奖励而不断更新策略参数，最终学习到能获得较高长期回报的行为方式。

以本文的立方体物块抬升任务为例，在某一时刻，对机械臂末端位置、夹爪




图 2-1 强化学习智能体-环境交互原理图

状态和物块位置进行观测，然后策略会输出末端位移和夹爪动作。环境执行动作之后，物块位置、末端位置和夹爪状态都会发生变化，同时会根据机械臂是否接近物块、是否抓住物块、是否稳定抬升等条件返回奖励。如此循环进行下去，就构成了强化学习中的交互过程。

强化学习问题通常建模为马尔可夫决策过程。一个马尔可夫决策过程可表示为五元组

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma), \quad (2-6)$$

其中 $\mathcal{S}$ 为状态空间， $\mathcal{A}$ 为动作空间， P 为状态转移函数， r 为奖励函数， $\gamma \in [0, 1)$ 为折扣因子。状态转移函数表示智能体在状态 s 下执行动作 a 后转移到下一状态 s' 的概率：

$$P_{ss'}^a = P(s_{t+1} = s' | s_t = s, a_t = a). \quad (2-7)$$

其中 s_t 为时刻 t 的环境状态， a_t 表示时刻 t 选择的动作， s_{t+1} 表示下一时刻的状态。奖励函数表示智能体在状态 s 下执行动作 a 后所获得的期望反馈：

$$R_s^a = \mathbb{E}(r_{t+1} | s_t = s, a_t = a). \quad (2-8)$$

其中 r_{t+1} 为执行动作后获得的奖励。

折扣因子 γ 用于平衡近期奖励和远期奖励。当 γ 较小时，智能体更关注短期收益；当 γ 较大时，智能体更重视长期结果。在机械臂抓取任务中，若只关注短

期奖励，策略可能只学习到快速接近物体；若考虑长期奖励，策略才会倾向于完成接近、夹取、抬升和保持稳定的完整过程。

策略函数描述智能体在状态下选择动作的行为准则，通常记为

$$\pi(a|s) = P(a_t = a | s_t = s). \quad (2-9)$$

其中 $\pi(a|s)$ 表示策略函数，即在状态 s 下选择动作 a 的概率。

对于确定性策略，状态会直接映射到一个动作；对于随机策略，状态会映射到动作概率分布。SAC 属于随机策略方法，其策略网络输出动作分布，并从中采样动作执行。

从某一时刻开始，智能体未来能够获得的折扣累积回报定义为

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}. \quad (2-10)$$

其中 r_{t+k+1} 为未来第 $k+1$ 步获得的奖励， $\gamma \in [0, 1]$ 为折扣因子。强化学习的目标是学习策略 $\pi(a|s)$ ，使期望折扣回报最大：

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right]. \quad (2-11)$$

对于机械臂操作任务，状态可以由机械臂本体状态和物体状态组成，动作可以是关节控制量、末端速度或末端位移。奖励函数则用于刻画任务目标，例如接近物体、成功抓取、抬升物体和保持稳定等。

在实际任务中，环境往往并不完全满足完全可观测假设。真实系统中可能存在视觉遮挡、传感器噪声、物体姿态估计误差和控制延迟等问题，此时智能体获得的观测 o_t 只是状态 s_t 的一部分。该问题更严格地说可以建模为部分可观测马尔可夫决策过程。本文在仿真阶段直接使用低维状态观测，因此暂不引入循环神经网络或历史观测编码。但为了缓解单帧观测缺少速度信息的问题，本文在稳定判据中额外计算立方体物块速度和末端速度，并在奖励中加入运动惩罚。

强化学习中的价值函数用于评价状态或状态动作对的长期收益。状态价值

函数定义为

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^T \gamma^t r_t \mid s_0 = s \right], \quad (2-12)$$

动作价值函数定义为

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^T \gamma^t r_t \mid s_0 = s, a_0 = a \right]. \quad (2-13)$$

最优策略 π^* 是使所有状态下价值函数达到最大的策略，可表示为

$$\pi^* = \arg \max_{\pi} V^\pi(s). \quad (2-14)$$

若使用动作价值函数进行动作选择，则最优动作可由

$$a^* = \arg \max_a Q^*(s, a) \quad (2-15)$$

得到。基于价值的方法通过估计 Q 函数选择高价值动作，基于策略的方法直接优化策略参数，Actor-Critic 方法则同时学习策略和价值函数。机械臂连续控制任务中动作维度连续，难以像离散动作任务那样枚举所有动作，因此 Actor-Critic 结构被广泛使用。

随着深度神经网络的发展，价值函数和策略函数可以由神经网络近似表示。状态向量作为网络输入，网络输出动作、动作分布或价值估计。对于本文使用的低维状态，网络不需要处理图像特征，因而可以采用多层感知机结构。这种设计减少了训练复杂度，使实验重点集中在连续控制策略和稳定抬升奖励设计上。

2.3 Soft Actor-Critic (SAC) 算法

SAC 是一种离策略 Actor-Critic 算法，其核心特点是在最大化任务回报的同时最大化策略熵，从而鼓励策略探索。Actor-Critic 结构由策略网络和价值网络组成。策略网络也称为 Actor，负责根据状态输出动作分布；价值网络也称为 Critic，负责评价当前状态动作对的价值，并为 Actor 的参数更新提供方向。相比只学习价值函数的方法，Actor-Critic 更适合连续动作空间；相比只使用策略梯度的方

法，Critic 能够降低策略更新方差，提高训练效率。

SAC 的最大熵目标函数可写为

$$J(\pi) = \sum_{t=0}^T \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t))], \quad (2-16)$$

其中 α 为熵温度系数， $\mathcal{H}$ 表示策略熵。策略熵定义为

$$\mathcal{H}(\pi(\cdot|s)) = \mathbb{E}_{a \sim \pi} [-\log \pi(a|s)]. \quad (2-17)$$

熵越大，说明策略在多个动作之间分布更均匀，探索性更强；熵越小，说明策略更倾向于选择少数高价值动作，利用性更强。较大的熵鼓励策略在训练早期保持随机探索，较小的熵则使策略在任务收敛后更加确定。

SAC 通常包含一个 Actor 网络、两个 Critic 网络、两个 Target Critic 网络以及经验回放池。设置两个 Critic 网络的目的是缓解价值函数过估计问题；Target Critic 网络用于构造相对稳定的训练目标；经验回放池用于保存历史交互样本。训练时，算法从回放池中随机抽取 (s_t, a_t, r_t, s_{t+1}) 样本，分别更新 Critic、Actor 和温度系数。

SAC 的软 Q 函数更新目标可表示为

$$y = r + \gamma \left(\min_{i=1,2} Q_{\bar{\theta}_i}(s', a') - \alpha \log \pi_\phi(a'|s') \right), \quad (2-18)$$

其中 $Q_{\bar{\theta}_i}$ 为目标 Q 网络， a' 由当前策略在下一状态 s' 下采样得到。使用两个 Q 网络并取较小值，可以减轻价值函数过估计问题。策略网络的优化目标为

$$J_\pi(\phi) = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_\phi} \left[\alpha \log \pi_\phi(a|s) - \min_{i=1,2} Q_{\theta_i}(s, a) \right], \quad (2-19)$$

其中 $\mathcal{D}$ 为经验回放池。该目标鼓励策略选择高 Q 值动作，同时通过熵项保持探索。

温度系数 α 控制熵项权重。当 α 较大时，策略更随机，探索更充分；当 α 较小时，策略更倾向于选择当前估计价值较高的动作。实际训练中常使用自动熵系数调整，使策略熵接近目标熵。本文实验采用自动温度调节方式，使策略能够

在探索和利用之间保持较好的平衡。

SAC 的离策略特性使其可以从历史数据中反复采样训练，这对机械臂仿真任务较为重要。机械臂每一步仿真都需要进行动力学计算和接触求解，采样成本高于普通数值环境。经验回放能够提高样本利用率，使相同交互数据多次参与网络更新。与此同时，回放池也会混合早期低质量数据和后期高质量数据，因此学习率、批大小、回放池大小和起始学习步数都会影响训练稳定性。

表 2-1 SAC 算法训练流程

输入： 环境 $\mathcal{E}$ ，折扣因子 γ ，软更新系数 τ ，批大小 B ，目标熵 $\mathcal{H}_{target}$ 。
初始化： Actor 网络 π_ϕ ，两个 Critic 网络 $Q_{\theta_1}, Q_{\theta_2}$ ，两个 Target Critic 网络 $Q_{\bar{\theta}_1}, Q_{\bar{\theta}_2}$ ，经验回放池 $\mathcal{D}$ ，温度系数 α 。
1. for 每一个训练回合 do 2. 重置环境，获得初始状态 s_0 ; 3. for 每一个控制步 t do 4. 根据当前策略采样动作 $a_t \sim \pi_\phi(\cdot s_t)$; 5. 在环境中执行 a_t ，获得奖励 r_t 和下一状态 s_{t+1} ; 6. 将转移样本 (s_t, a_t, r_t, s_{t+1}) 存入经验回放池 $\mathcal{D}$; 7. 从 $\mathcal{D}$ 中采样 mini-batch，样本数量为 B ; 8. 对每个样本，根据当前 Actor 在 s_{t+1} 处采样下一动作 a' ; 9. 计算软 Bellman 目标 $y = r_t + \gamma (\min_{i=1,2} Q_{\bar{\theta}_i}(s_{t+1}, a') - \alpha \log \pi_\phi(a' s_{t+1}))$; 10. 最小化 $(Q_{\theta_i}(s_t, a_t) - y)^2$ ，更新两个 Critic 网络; 11. 最小化 $\alpha \log \pi_\phi(a s_t) - \min_{i=1,2} Q_{\theta_i}(s_t, a)$ ，更新 Actor 网络; 12. 根据目标熵 $\mathcal{H}_{target}$ 自动调整温度系数 α ; 13. 软更新目标网络: $\bar{\theta}_i \leftarrow \tau \theta_i + (1 - \tau) \bar{\theta}_i$; 14. 令 $s_t \leftarrow s_{t+1}$; 15. end for 16. end for 输出： 训练后的策略网络 π_ϕ 。

2.4 手眼标定

手眼标定的目标是求解相机坐标系与机械臂基坐标系之间的外参。根据相机安装方式不同，常见形式包括 eye-in-hand 和 eye-on-base。eye-in-hand 表示相机安装在机械臂末端执行器处，随着机械臂运动而运动；eye-on-base 表示相机固定在环境里，相机相对于机械臂基坐标系保持不变。本文真实系统采用 eye-on-base 方式，即 RealSense 相机固定在工作空间外部，标定目标是求解机械臂基坐标系到相机标定光学坐标系的变换。

齐次变换矩阵可以表示一个坐标系相对于另一个坐标系的位姿：

$${}^A T_B = \begin{bmatrix} {}^A R_B & {}^A t_B \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad (2-20)$$

其中 ${}^A R_B$ 为坐标系 B 到坐标系 A 的旋转矩阵， ${}^A t_B$ 为坐标系 B 原点在坐标系 A 下的位置。对于真实抓取任务，若视觉检测得到物体相对于相机的变换 ${}^{camera} T_{cube}$ ，手眼标定得到相机相对于机械臂基坐标系的变换 ${}^{base} T_{camera}$ ，则物体在机械臂基坐标系下的位姿为

$${}^{base} T_{cube} = {}^{base} T_{camera} {}^{camera} T_{cube}. \quad (2-21)$$

该式是将视觉检测结果用于真实机械臂控制的基础。只有得到 ${}^{base} T_{cube}$ 后，才能与机械臂正运动学给出的末端位姿 ${}^{base} T_{eff}$ 在同一坐标系下计算相对位置。

第三章 系统设计与实现

3.1 总体架构

本文围绕“机械臂抓取并稳定抬升桌面立方体物块”这个任务来展开，包括仿真训练系统和真实平台部署系统两部分。仿真训练系统用来构建可重复交互的强化学习环境，进行状态构造、动作执行、奖励计算和策略训练；真实平台部署系统用来把训练后的策略迁移到 Franka Research 3 机械臂上，通过视觉定位和坐标变换构造与仿真相一致的低维观测，并且把策略输出转换为真实机械臂能够执行的受限运动命令。虽然这两部分的运行平台不一样，但是都是围绕着同一种状态动作接口来展开的，这也是本文实现 sim-to-real 验证的基础。系统总体的方法框架如图3-1所示。

在仿真阶段，MuJoCo 负责进行动力学仿真和接触求解，robosuite 提供 Lift 任务接口。为了和 Stable-Baselines3 里的 SAC 算法相兼容，本文在 robosuite 环境的外部设计了 Gymnasium 包装器，对原始观测进行筛选和拼接，把它转换为固定长度的低维状态向量；同时，它还能将 SAC 输出的归一化动作映射成末端执行器的小幅度位置增量和夹爪开合命令。在训练过程中，包装器还负责记录抬升高度、速度、动作幅值、成功状态等中间变量，为后续的奖励改进和实验分析提供数据。

在真实部署阶段，系统不再能够直接获取物体的位姿，因此需要通过 RealSense 相机和 ArUco 标记来估计立方体物块在相机坐标系下的位姿；接着利用手眼标定的结果，把它转换到机械臂基坐标系下。机械臂末端的位置可以通过机械臂状态反馈和 TF 坐标系统得到。这样，真实系统就可以构造出和仿真环境形式一致的观测向量。策略输出之后，真实执行模块会进一步进行动作限幅、低通滤波、工作空间约束和安全裁剪，然后发送给机械臂执行。

因此，本文系统的核心流程可以概括为：首先从仿真环境或真实感知系统获取末端和物体的状态；然后把这些状态整理成统一的低维观测；接着由 SAC 策




图 3-1 仿真实验到真机验证的方法框架

略输出连续动作；最后通过动作转换模块将动作变为仿真环境或者真实机械臂可以执行的控制命令。这样的设计能让强化学习策略尽量不依赖具体平台接口，而由环境包装器和部署模块吸收仿真与真实系统之间的差异。

3.2 仿真环境与状态动作空间

本文基于 `robosuite` 的 `Lift` 任务开展实验。该任务包含一张桌子、一个立方体物块、一个单臂机械臂和一个二指夹爪。机械臂需要从初始位姿出发，移动到物块附近，闭合夹爪抓取物块，并将其从桌面上抬起。

环境关键参数如表 3-1 所示。

表 3-1 仿真环境主要参数

参数	取值
仿真平台	MuJoCo + <code>robosuite</code>
任务名称	<code>Lift</code>
机械臂模型	<code>FR3v2</code>
控制器	<code>OSC_POSITION</code>
控制频率	20 Hz
单回合最大步数	200
是否使用图像观测	否
是否使用物体状态观测	是
强化学习算法	<code>SAC</code>

在 `robosuite` 原始 `Lift` 任务中，当立方体物块高度超过桌面一定阈值时即判定为成功。此定义可以用来衡量是否完成了“抬起”动作，不过无法度量抬起后的稳定性。本文在外部包装器里引入了更严格的稳定保持指标。

在环境创建时，关闭了相机图像观测，策略不直接使用图像作为输入；同时保留了低维物体状态，使环境可以提供立方体物块的位置、姿态以及末端与物块之间的相对位置等信息。此设置适合本文当前阶段的算法验证，因为它避免了视觉识别误差对强化学习训练造成影响，让研究重点能够集中在连续控制策略和稳定抬升目标上。

在控制器方面，本文使用了操作空间位置控制器。该控制器会接收末端位置增量，不需要策略直接输出关节角度或者关节力矩。对于立方体物块抬升任务，末端位置控制可以表达出接近、下降、夹取和上抬等主要动作。和同时控制末端位置与姿态的方式相比，只控制末端位置的动作维度更低，训练难度也更小。和关节控制相比，末端位置动作更符合任务空间直觉。

Lift 环境的单回合最大步数是 200，控制频率是 20 Hz，因此一个完整回合对应的仿真时间大约是 10 秒。若策略在回合内达到稳定保持成功条件，包装器可提前终止回合；若未达到成功条件，则回合在 200 步时因时间限制结束。

为了降低训练难度，本文不使用图像作为输入，而是使用低维状态观测。单步观测向量维度为 14，具体组成如表 3-2 所示。

表 3-2 低维观测向量组成

索引范围	维度	含义
0:3	3	机械臂末端位置
3:4	1	夹爪开合量
4:7	3	立方体物块位置
7:11	4	立方体物块四元数姿态
11:14	3	末端到立方体物块的相对位置

该状态设计的优点是维度低、学习效率高，并且能够直接反映抓取任务所需的几何关系。其不足是依赖仿真环境提供的精确物块位姿。在真实机械臂部署时，需要通过视觉定位估计物块位姿。

观测向量由环境包装模块生成。该模块从环境返回的观测信息中提取末端位置、夹爪开合量、立方体物块位置、立方体物块姿态以及末端到立方体物块的相对位置，并按固定顺序拼接为一维数组。其中，夹爪原始关节状态被压缩为一维开合量，以减少冗余信息。

状态空间各部分的作用如下：末端位置用于描述机械臂当前执行器位置；夹爪开合量用于判断夹爪是否处于打开、闭合或半闭合状态；立方体物块位置用于提供目标物体的空间坐标；立方体物块四元数用于描述物体姿态；末端到立方体物块的相对位置直接反映抓取任务中最重要的几何误差。相比仅使用末端位置和物体位置，相对位置能够减少神经网络自行学习坐标差的负担。

本文当前没有把速度信息直接加入策略观测，主要原因是希望保持状态维度较低，并先验证位置状态下的抓取能力。速度信息虽然不作为策略输入，但会在稳定抬升判据和奖励函数中使用，用于判断物体和末端是否已经保持稳定。

本文采用 OSC_POSITION 控制器。策略动作向量为 4 维：

$$\mathbf{a} = [a_x, a_y, a_z, a_g]^T, \quad (3-1)$$

其中前三维表示末端执行器在操作空间中的位置增量，最后一维表示夹爪开合

控制。动作范围为 $[-1, 1]$ 。需要注意的是，robosuite 暴露给策略的动作是归一化动作，底层控制器会将其映射到实际末端位移范围。因此，在进行工作空间裁剪时，不能直接把归一化动作当作米制位移，而应先转换到控制器实际输出尺度，再进行裁剪。

本文包装器中实现了归一化动作与末端位移之间的双向转换：

$$\Delta x = \frac{a - a_{\min}}{a_{\max} - a_{\min}}(\Delta x_{\max} - \Delta x_{\min}) + \Delta x_{\min}. \quad (3-2)$$

这样可以保证工作空间约束与真实几何尺度一致。

具体而言，策略网络输出的前三维动作 a_x, a_y, a_z 位于 $[-1, 1]$ 区间内。操作空间控制器内部会将其缩放到实际末端位置增量范围。以默认配置为例，归一化动作 $[-1, 1]$ 对应的末端位置增量约为 $[-0.05, 0.05]$ m。若在工作空间裁剪时直接将归一化动作当作米制位移，就会导致裁剪尺度错误。因此，本文在包装层中显式加入了“归一化动作到米制末端增量”和“米制末端增量到归一化动作”的双向转换机制。

动作执行过程如下：首先读取上一时刻的末端位置；然后将策略输出动作转换为米制末端增量；再计算策略意图中的下一末端目标位置；若该目标位置超出工作空间，则将其投影回可行空间；最后再把裁剪后的米制增量转换回归一化动作，并发送给 robosuite 环境执行。

夹爪动作 a_g 不参与工作空间位置裁剪，而是直接传递给 robosuite 控制器。训练过程中策略需要同时学习末端移动和夹爪闭合时机。如果夹爪过早闭合，可能夹空；如果闭合过晚，可能推开立方体或错过抓取时机。

3.3 训练流程与实验记录

robosuite 原始环境接口与 Gymnasium 接口并不完全一致。为了让 Stable-Baselines3 的 SAC 算法能够直接训练，本文设计了环境包装模块。该模块负责连接 robosuite 原始环境和强化学习算法，完成接口转换、观测整理、动作处理、奖励补充以及日志信息整理。

在初始化阶段，包装模块会完成下面这些工作：加载操作空间位置控制器配置，创建 robosuite Lift 环境，读取环境动作的上下界并构造连续动作空间，获取

样例观测，再跟据观测信息构造 14 维观测空间，同时保存工作空间参数，方便检查环境配置是否正确。

在每个回合开始的时候，包装模块会重置环境，还会把稳定保持计数器清空，来保证每个回合都可以独立进行统计。在每个控制步里，包装模块会接收 SAC 策略输出的动作，先对动作范围进行裁剪，接着完成动作尺度转换和工作空间约束，然后把处理后的动作发送给原始环境。环境返回新观测、原始奖励、回合结束标志和诊断信息之后，包装模块会继续计算稳定抬升指标、附加奖励和日志信息，最后以 Gymnasium 格式返回给算法。

该包装器的设计使任务逻辑与 robosuite 源码保持解耦。本文没有直接修改 robosuite 的 Lift 环境，而是在外部包装器中添加低维观测、稳定保持指标和日志字段。这样既便于调试，也便于后续切换其他任务或真实机械臂接口。

SAC 训练参数如表 3-3 所示。

表 3-3 SAC 训练参数

参数	取值
策略网络	MlpPolicy
学习率	1×10^{-4}
回放池大小	200000
批大小	256
起始学习步数	5000
折扣因子 γ	0.99
软更新系数 τ	0.005
熵系数	自动调整
总训练步数	500000
评估间隔	5000

训练环境和评估环境分别创建，二者结构相同但用途不同。训练环境用于收集交互数据并更新策略，评估环境用于定期测试当前策略性能。本文设置每 5000 步进行一次评估，每次评估运行多个回合，并保存平均奖励最高的模型。

训练过程中使用日志记录与评估机制保存回合奖励、回合长度以及自定义成功字段。训练监控模块用于统计最近若干回合的成功率，评估模块用于周期性计算稳定保持成功率、原始抬升成功率和受控抬升成功率。

实验输出统一保存到项目的工作目录中。该目录下包含最佳模型、最终模型、评估日志和 TensorBoard 日志。评估回调会自动保存最佳模型，训练结束之后会保存最终模型。这样的目录结构可以方便之后复现实验、比较不同训练版

本，还可以加载模型进行可视化。

3.4 稳定抬升控制方法

3.4.1 问题分析

在初始实验中，策略能够以较高成功率将立方体物块抬离桌面。然而，通过可视化观察可以发现，部分策略在抓住立方体并抬升到一定高度后仍持续上抬，或者末端在空中随机摆动，如图3-2所示。造成该现象的原因主要有三点。




图 3-2 机械臂抓取物块后的过度上抬

第一，原始成功条件过于宽松。robosuite 的 Lift 任务只判断立方体是否高于桌面阈值，并不关心抬升高度是否合适，也不关心抬升后是否稳定。

第二，奖励函数偏向“尽快抬起”。如果策略只要抬高物体就能获得较高奖励，而过度动作没有足够惩罚，那么策略可能学习到幅度较大的上抬动作。

第三，训练指标与实际期望不一致。若 TensorBoard 中的成功率只表示“曾经抬起过”，则无法反映末端摆动和物体不稳定问题。因此需要重新定义评价指标。

3.4.2 工作空间约束

为避免策略产生不可达或危险动作，本文将末端目标限制在圆柱形工作空间内。设末端目标位置为 (x, y, z) ，其水平半径为

$$r = \sqrt{x^2 + y^2}. \quad (3-3)$$

工作空间约束为

$$r_{\min} \leq r \leq r_{\max}, \quad z_{\min} \leq z \leq z_{\max}. \quad (3-4)$$

当策略输出的目标位置超出范围时，系统将目标投影回可行区域，并记录边界惩罚。

3.4.3 稳定抬升判据

本文将成功行为分为三个层次：

1. 原始抬升成功：立方体物块高度超过 robosuite 原始阈值；
2. 受控抬升成功：立方体物块接近目标抬升高度，且速度较小；
3. 稳定保持成功：受控抬升状态连续保持若干控制步。

设立方体物块相对桌面的高度为 h ，目标抬升高度为 h^* 。当满足

$$|h - h^*| \leq \epsilon_h \quad (3-5)$$

且物块速度和末端速度均低于阈值时，判定为受控抬升。若受控抬升状态连续保持 N 个控制步，则判定为稳定保持成功。

3.4.4 奖励函数改进

本文在 robosuite 原始 shaped reward 基础上加入稳定抬升奖励项。总体奖励可表示为

$$r = r_{\text{base}} + r_{\text{height}} + r_{\text{stable}} - p_{\text{motion}} - p_{\text{action}} - p_{\text{boundary}}. \quad (3-6)$$

其中 r_{base} 为环境原始奖励, r_{height} 鼓励立方体物块高度接近目标高度, r_{stable} 奖励稳定状态, p_{motion} 惩罚物体和末端速度, p_{action} 惩罚过大的动作, p_{boundary} 惩罚超出工作空间的意图。

高度奖励采用指数形式:

$$r_{\text{height}} = c_h \exp(-k_h |h - h^*|). \quad (3-7)$$

该形式在目标高度附近提供较高奖励, 在偏离目标高度时快速衰减。对于超过最大允许高度的情况, 额外加入过抬升惩罚, 以抑制策略持续向上运动。

3.4.5 评价指标设计

为了避免单一成功率掩盖策略行为问题, 本文记录以下指标:

表 3-4 评价指标说明

指标	含义
raw_lift_success_rate	原始抬升成功率, 仅判断是否抬离桌面
controlled_lift_success_rate	受控抬升成功率, 判断高度和速度是否满足要求
held_success_rate	稳定保持成功率, 判断是否连续稳定保持
mean_ep_length	平均评估回合长度
mean_reward	平均评估回报
cube_speed	立方体物块速度
eef_speed	末端执行器速度

其中, held_success_rate 是最符合本文任务目标的指标。如果 raw_lift_success_rate 较高而 held_success_rate 较低, 说明策略能够抬起物体但无法稳定保持; 如果 controlled_lift_success_rate 较高而 held_success_rate 较低, 说明策略能短暂到达理想状态但保持能力不足。

3.5 真实平台部署设计

3.5.1 真实系统组成

在仿真训练完成后, 本文将训练得到的最优策略部署到 Franka Research 3 真实机械臂上进行验证。真实系统由机械臂本体、末端夹爪、视觉感知模块、坐标变换模块、策略推理模块和安全执行模块组成。其中, 机械臂平台为 Franka

Research 3，末端执行器为 Franka Hand；视觉传感器采用 Intel RealSense D455 相机；物体位姿通过粘贴在立方体物块上的 ArUco 标记进行估计；机械臂控制和坐标查询通过 ROS 2、MoveIt 2 和 TF2 完成。

真实部署流程与仿真训练流程的核心区别在于，仿真中可以直接从 MuJoCo 读取末端和物体状态，而真实系统必须通过机械臂状态反馈和视觉检测获得这些量。因此，真实系统首先需要保证两个坐标链路稳定：一是机械臂基坐标系到末端 TCP 坐标系的变换，二是机械臂基坐标系到立方体中心坐标系的变换。只有当末端位姿和物体位姿被统一到同一个基坐标系下，仿真中训练得到的低维策略观测才可以在真实机械臂上构造。

真实系统的组成如图3-3所示。真实系统的运行流程为首先启动 RealSense 相机节点，发布 RGB 图像和相机内参；然后启动 ArUco 检测节点，根据图像和内参估计立方体相对于相机的位姿；接着通过手眼标定外参将相机坐标系连接到机械臂基坐标系；随后启动 Franka Research 3 的 MoveIt 2 控制系统，获得末端 TCP 在基坐标系下的实时位姿；最后由真实策略执行模块加载训练得到的最优策略模型，构造真实观测、推理策略动作，并将动作转换为受限的笛卡尔线性运动。



图 3-3 真实系统组成

3.5.2 视觉定位与坐标变换

RealSense D455 相机以 RGB 模式运行，图像分辨率设置为 1280×720 ，帧率为 30 Hz。相机节点发布彩色图像和相机内参。ArUco 检测节点订阅上述图像和内参，识别贴在立方体物块上的标记，并发布物块在相机光学坐标系下的位姿。该位姿进一步作为 TF 中的物体坐标系。

本文只使用 RGB 图像进行 ArUco 位姿估计，因此关闭深度流。这样可以减少系统带宽和节点计算负担，同时避免深度噪声对位姿估计产生额外影响。相机内参信息包含相机内参矩阵、畸变参数和图像分辨率。ArUco 节点根据内参将标记角点从像素坐标反投影到三维空间，并结合标记实际边长估计标记相对于相机的 6D 位姿。

在实现中，视觉定位模块订阅彩色图像和相机内参，并输出立方体物块在相机标定光学坐标系下的位置和姿态。该输出包含立方体中心位置 p 和姿态四元数 q 。节点同时将检测到的物体位姿发布为 TF 中的物体坐标系，使后续控制程序可以直接通过 TF2 查询机器人基坐标系到物体的变换。由于本文策略主要依赖末端位置、物体位置和相对位置完成抓取，物体姿态主要用于保持与仿真观测维度一致。

本文将手眼标定结果作为静态坐标变换发布到 TF 系统中。发布该静态变换后，可以分别检查机械臂基坐标系到立方体物块坐标系、机械臂基坐标系到末端 TCP 坐标系的变换结果。前者用于检查物体是否位于真实桌面任务区域，后者用于检查机械臂 TCP 位姿是否正常。只有这两个查询都稳定输出，才说明真实策略推理所需的坐标链已经建立。

3.5.3 真实观测构造

本文在真实机器人上保持与仿真训练一致的低维观测结构。真实观测向量为

$$o = [p_{eef}, g, p_{cube}, q_{cube}, p_{cube} - p_{eef}], \quad (3-8)$$

其中，所有的位置量都是在机械臂基坐标系下进行表示的， g 表示夹爪开合状态， q_{cube} 表示立方体物块姿态四元数。这个观测结构和仿真中的 14 维低维状态保持一致，从而避免了在真实部署的时候改变策略网络的输入维度。

在真实系统中，物体位姿是通过视觉检测得到的，会受到标记检测误差、相机噪声和时间延迟的影响。为了减少噪声对动作的影响，真实执行程序对策略输出的位置动作进行了低通滤波，还设置了每步最大末端位移限制。这样可以在保持策略趋势的同时，避免单帧视觉抖动导致机械臂产生突然运动。

真实观测由策略执行模块完成。这个模块会先读取控制器维护的当前 TCP 位姿，接着通过 TF2 查询机械臂基坐标系到立方体坐标系的变换情况，最后计算出相对位置

$$\mathbf{p}_{rel} = \mathbf{p}_{cube}^{base} - \mathbf{p}_{ee}^{base}. \quad (3-9)$$

程序把末端位置、夹爪开合状态、立方体物块位置、立方体物块四元数还有相对位置，按照仿真训练时的相同顺序构造拼接成 NumPy 数组，然后输入到 SAC 策略网络里。这样做的关键是要保证真实观测和仿真观测在维度、顺序、单位以及坐标系上的一致性。

在程序启动阶段，系统会持续检查两个条件：第一，控制器已经可以提供末端 TCP 位姿；第二，TF2 能查询到机械臂基坐标系到立方体物块坐标系的变换。若相机没有识别出 ArUco 标记，或者静态手眼标定 TF 没有发布，系统会等待，不会进入执行阶段。这样的设计可以防止在观测不完整的时候向真实机械臂发送错误的动作。

3.5.4 动作执行与安全裁剪

训练策略输出的动作为

$$\mathbf{a} = [a_x, a_y, a_z, a_g]^T, \quad (3-10)$$

其中前三维为归一化的末端位置增量，第四维为夹爪开合动作。真实部署时不能将 a_x, a_y, a_z 直接作为米制位移，而是先按照仿真中操作空间位置控制器的动作尺度转换为末端位移。本文实机实验中以 0.05 m 作为归一化动作的基础尺度，并将单次真实执行位移限制在 1 mm 左右。实际执行命令可表示为

$$\Delta \mathbf{x}_{real} = \text{clip}(\alpha \mathbf{a}_{xyz}, -\Delta_{max}, \Delta_{max}), \quad (3-11)$$

其中 α 为动作尺度系数, Δ_{max} 为真实机械臂单步位移上限。

真实机械臂的笛卡尔运动是通过 MoveIt 2 的笛卡尔线性路径接口来执行的。控制模块会把每一步的策略输出转化为一个小幅度的 TCP 目标位置, 然后由 MoveIt 2 规划并执行线性笛卡尔路径。和直接使用普通位姿规划相比, 这种方式 and 仿真中的操作空间位置增量控制形式更接近, 也更适合低速、安全地对强化学习策略进行验证。

夹爪的动作是由策略输出的第四维 a_g 来决定的。当 a_g 小于设定的阈值时, 真实系统就会触发 Franka Hand 闭合命令; 在夹爪闭合之后, 程序会执行竖直抬升动作, 实机实验中使用的抬升高度是 0.075 m, 与第一阶段仿真训练的目标相一致。

在每个控制周期中, 真实策略执行模块会首先构建真实观测, 接着加载策略模型进行确定性推理, 从而得到四维动作。然后动作转换模块会把前三维动作转化成真实末端位移。这个过程包含三层安全处理, 第一层是把策略动作裁剪到 $[-1, 1]$; 第二层是对动作做低通滤波, 避免视觉噪声导致动作跳变; 第三层是将位移裁剪到预设的最大单步距离, 并进一步限制到设定工作空间内。

在真实执行阶段, 系统设置了较低的策略执行频率、较小的单步末端位移、未抓取前的最低接近高度、夹爪使能开关以及抓取后的竖直抬升动作。线性运动控制模块负责把目标末端位置发送给 MoveIt 2, 通过笛卡尔路径接口来生成线性 TCP 轨迹。和普通位姿规划相比, 笛卡尔线性路径更容易让末端运动方向与策略输出保持一致, 可以有效减少绕行和姿态突变。夹爪闭合由策略第四维动作 a_g 触发, 当该动作小于阈值时, 系统就会执行 Franka Hand 闭合。

第四章 实验结果与分析

4.1 仿真实验设置

实验在本地计算环境中进行,使用 robosuite 创建仿真环境,用 Stable-Baselines3 实现 SAC 训练。实验任务是让 Franka Research 3 机械臂在 Lift 环境中抓取桌面立方体物块,并且把它抬升到目标高度附近之后保持稳定。训练总步数为 500000 步,控制频率为 20 Hz,单回合最大长度为 200 步。每隔一定的步数就进行一次评估,并且记录平均奖励、平均回合长度、原始抬升成功率、受控抬升成功率和稳定保持成功率。训练日志可以通过 TensorBoard 进行可视化。

训练开始之后,系统会按照预设的训练步数进行环境交互和网络更新,还会在固定的间隔执行评估。训练日志通过 TensorBoard 可视化。本章分析的实验曲线来自一次完整训练记录。

4.2 仿真训练收敛性分析

为验证 SAC 算法在机械臂立方体物块抬升任务中的训练效果,本文选取训练过程中的平均回合奖励和平均回合长度作为收敛性评价指标。其中,平均回合奖励用于反映智能体在交互过程中获得的累计收益,平均回合长度用于衡量智能体完成任务所需的交互步数。一般而言,若平均回合奖励随训练过程逐渐上升,且平均回合长度呈下降或稳定趋势,则说明智能体逐渐学习到有效的操作策略。

由图4-1可以看出,在训练初期,智能体尚未掌握稳定的抓取与抬升策略,平均回合奖励处于较低水平,平均回合长度接近环境设定的最大步数。这说明随机初始化策略难以在有限时间内完成有效抓取,机械臂主要表现为探索性动作。随着训练步数增加,平均回合奖励整体呈明显上升趋势,表明智能体通过与环境持续交互,逐渐学习到接近目标物体、闭合夹爪以及抬升立方体物块等关键动作。




图 4-1 平均奖励与平均回合长度变化曲线

同时，平均回合长度在训练过程中整体下降，说明智能体完成任务所需的交互步数逐渐减少，策略执行效率有所提高。训练后期，平均奖励趋于较高水平并伴随一定波动，这是由于机械臂操作任务涉及接触动力学、夹爪闭合时机以及物体姿态变化等因素，强化学习训练过程本身也具有一定采样随机性。因此，奖励曲线并不会严格单调上升。综合平均回合奖励和平均回合长度的变化可以看出，SAC 算法在该立方体物块抬升任务中能够有效提升策略性能，并逐渐形成较为稳定的操作行为。

4.3 任务成功率分析

为进一步评价 SAC 策略在立方体物块抬升任务中的实际完成效果，本文从任务完成程度和操作稳定性两个角度出发，设置了三类成功率指标，分别为原始抬升成功率、受控抬升成功率和稳定保持成功率。三类指标的判定标准是从宽到严的，这样可以更细致地反映智能体从“将物体抬起”到“稳定、受控地完成抬升”的策略学习过程。

其中，原始抬升成功率是用来衡量物块能不能被抬升到 robosuite 环境原始成功判据所设定的高度阈值以上。这个指标主要体现智能体有没有基本的抓取和抬升能力，它是最基础的任务完成指标。受控抬升成功率是在原始抬升的基础上进一步引入目标高度和速度约束，也就是要求物体不但要接近预设目标抬升高度，而且运动速度要较小。这个指标可以排除由瞬时碰撞、快速甩动或不稳定接触导致的偶然抬升，更强调抬升过程的可控性。稳定保持成功率则要求受控抬升状态能够连续保持若干个控制步，用来评估智能体在完成抬升后能否维

持稳定抓持与平稳保持状态，是三类指标里最严格的成功判据。




图 4-2 评估成功率变化曲线

由图4-2可以看出，在训练初期，三类成功率都接近 0，这意味着随机初始化策略很难完成有效的抓取和抬升操作。随着训练步数增多，三条成功率曲线整体呈上升趋势，这说明 SAC 智能体在和环境持续交互的过程中，逐渐学习到了接近目标物体、闭合夹爪、抬升立方体物块以及保持物体稳定等关键操作行为。

从不同成功率指标的变化趋势来看，原始抬升成功率最早出现明显提高，在训练的中后期达到了较高的水平。这表明智能体最先学习到的是把立方体物块抬离桌面的基本动作策略，也就是可以通过夹爪接触和末端执行器上移使目标物体满足高度阈值要求。不过，原始抬升成功率较高并不代表任务已经稳定、受控地完成了，因为这个指标主要关注高度有没有达到阈值，但是没有充分约束物体的运动速度和保持时间。

相比之下，受控抬升成功率的提升相对滞后，它的数值整体上比原始抬升成功率要低。这说明在机械臂操作任务中，把物体抬起来相对容易一些，但是要使物体以较小速度接近目标高度并且保持运动稳定则会更加困难。受控抬升成功率的持续上升意味着智能体在训练的后期逐渐减少了不稳定抬升、快速冲击和物体晃动等情况，策略的运动控制质量得到了提高。

稳定保持成功率进一步低于原始抬升成功率，并且在训练过程中存在一定

波动。这是因为稳定保持成功率不仅要求立方体物块达到受控抬升得状态，而且要求该状态连续维持若干控制步，这对夹爪闭合时机、抓取姿态、末端执行器的轨迹和物体接触的稳定性都提出了更高的要求。当夹爪和立方体物块之间的接触不够充分，或者抬升后物体出现滑移、晃动以及速度过大的情况时，稳定保持成功率就会降低。所以，这个指标可以更加严格地反映策略在抓取稳定性和任务鲁棒性方面的表现。


综合起来看，三种成功率指标呈现出比较清晰的层次关系：原始抬升成功率最高，说明智能体已经具备了基本的抬升能力；受控抬升成功率在逐步提高，说明策略在目标高度控制和运动平稳性方面在不断改进；稳定保持成功率在训练后期达到了较高的水平，说明智能体不仅能将立方体物块成功抬起来，而且还可以在一定的时间内保持相对稳定的受控抬升状态。这个结果表明，SAC 算法可以有效学习立方体物块抬升任务中的关键操作策略，并逐步提升机械臂操作的成功率、可控性和稳定性。

4.4 仿真可视化行为分析


为更加直观地展示训练后策略在立方体物块抬升任务中的执行效果，本文对训练完成后的 SAC 策略进行可视化测试，并选取机械臂操作过程中的若干关键帧进行展示，如图4-3所示。关键帧依次对应机械臂的初始状态、接近目标物体、夹爪闭合抓取、立方体物块抬升且稳定保持等阶段，能够较完整地反映策略执行过程中的行为变化。

可以看出，在任务开始阶段，物块位于桌面指定区域，机械臂末端执行器处于初始位姿。随后，策略会根据当前的观测状态，对控制末端执行器进行控制让它逐渐朝着物块靠近。在接近目标以后，智能体控制夹爪完成闭合，从而达到对物体有效夹持的目的。完成抓取之后，机械臂末端会沿着竖直方向向上移动，把物体从桌面抬起来，并最终在目标高度附近保持相对稳定。


从可视化结果可以看出，训练后的 SAC 策略可以较好地完成从“接近—抓取—抬升—保持”的连续操作过程。这个过程和前文成功率曲线以及抓取行为指标的变化结果相互印证。原始抬升成功率提高了，表明了智能体具备把物体抬离桌面的能力；受控抬升成功率的提升表明了策略能在较小速度下接近目标




(a) 初始状态



(b) 接近目标



(c) 完成抓取



(d) 抬升且稳定保持

图 4-3 训练后 SAC 策略在立方体物块抬升任务中的可视化执行过程

高度；稳定保持成功率提高，则说明智能体在抬升后能维持较稳定的抓取状态。可视化实验进一步地验证了本文训练的策略在立方体物块抬升任务中的有效性。

4.5 真实机械臂验证结果

完成相机标定、TF 坐标链配置和控制程序调试后，本文在 Franka Research 3 真实机械臂上进行了 sim-to-real 验证。实验过程中，RealSense 相机持续检测立方体位姿，TF 系统实时提供机器人基坐标系下的立方体物块位姿和末端位姿。策略执行模块加载仿真训练得到的最优策略模型，按照 1 Hz 左右的低频率输出动作，并通过笛卡尔线性控制接口执行。




图 4-4 Franka Research 3 真实平台上的立方体抬升验证

从图4-4可以看出，机械臂能够根据视觉检测到的立方体物块位置逐步接近目标，并在靠近物体后由策略输出的夹爪动作触发闭合。夹爪闭合后，机械臂执行竖直抬升，物块随夹爪离开桌面，说明仿真训练得到的策略在真实机械臂上完成了基本的抓取和抬升验证。这个结果表明，使用机械臂基坐标系构造观测、使用 ArUco 提供物体的位姿、并且把归一化策略动作转变为受限笛卡尔位移，是一条可行的低维策略 sim-to-real 路线。

真实实验也暴露出一些需要进一步改进的问题。第一，视觉检测的立方体物块位置有轻微抖动的现象存在，这会导致策略输出在接近阶段发生小幅度变化。

第二，真实控制链路中 MoveIt 2 规划和执行有一定的延迟，使得真实动作频率比仿真环境低。第三，夹爪闭合时机完全由策略四维动作所决定，如果视觉估计误差比较大，还是可能会出现提前闭合或偏心抓取的情况。后续可以进一步加入视觉滤波、夹爪接触检测、力反馈和更多次的重复实验，来提高真机验证的稳定性和统计可靠性。

4.6 真实机械臂安全措施

真实机械臂实验中，本文没有让强化学习策略直接输出关节力矩，而是采用“策略输出低频末端增量，控制器执行受限笛卡尔运动”的方式。程序中设置了工作空间边界、单步最大位移、最低接近高度、夹爪使能开关和人工停止机制。实验开始前先进行 shadow mode 测试，即只打印策略动作而不发送机器人命令；确认动作方向和坐标系一致后，再以较小速度进入真实执行模式。这些安全措施降低了策略从仿真迁移到真实平台时的风险。

第五章 总结与展望

5.1 全文总结

本文围绕“基于强化学习的机械臂操作算法研究”这一主题，基于 MuJoCo 和 robosuite 搭建了机械臂桌面立方体物块抬升任务环境，并使用 SAC 算法训练连续控制策略。本文设计了低维状态空间和操作空间位置动作空间，使策略能够学习末端运动和夹爪控制。针对初始策略中出现的过度上抬和随机摆动问题，本文提出了稳定抬升目标、工作空间约束、动作裁剪、运动惩罚和连续稳定保持成功判据。

实验分析表明，原始成功率只能反映物体是否被抬离桌面，不能准确评价策略是否稳定。通过引入 `raw_lift_success_rate`、`controlled_lift_success_rate` 和 `held_success_rate` 三类指标，可以更细致地分析策略行为。本文最终将 `held_success_rate` 作为主要任务指标，使训练目标更接近真实机械臂应用中“抬起并稳定保持”的需求。

在真实平台验证方面，本文进一步将仿真训练得到的策略部署到 Franka Research 3 机械臂上进行 sim-to-real 实验。真实系统通过 RealSense 相机和 ArUco 标记获取立方体位姿，并利用手眼标定将相机坐标系下的物体位姿转换到机械臂基坐标系下，从而构造与仿真训练一致的低维观测。真实执行阶段采用受限的笛卡尔线性控制方式，将策略输出的归一化动作转换为小幅度末端位移，并结合夹爪动作完成接近、夹取和抬升。实验结果说明，在坐标系统一、动作限幅和安全约束的基础上，本文训练得到的低维位姿策略能够完成从仿真到真实机械臂的迁移验证。

5.2 不足与展望

本文还是存在一些不足的地方。第一是当前的策略使用的是低维状态输入，在真实部署阶段要依赖 ArUco 标记来提供物体的位姿，尚未实现无标记的通用

视觉识别。第二是实验任务只包含单个立方体物块的抬升操作，还没有扩展到多物体抓取、放置或者装配任务。最后，本文已经在 Franka Research 3 上完成了相应的 sim-to-real 验证，但是真实实验次数有限，还未进行大规模重复实验、扰动实验和统计显著性分析。

后续工作可以从以下方向展开：

1. 引入更通用的视觉感知模块，减少对 ArUco 标记和人工标定流程的依赖；
2. 将任务扩展到 pick-and-place、堆叠和插孔等更复杂操作；
3. 使用域随机化提升策略对真实环境差异的鲁棒性；

本文完成了一个较为完整的机械臂强化学习操作算法实验流程，通过稳定保持指标对策略评价方式进行了改进，同时完成了基于 Franka Research 3 的 sim-to-real 验证，为后续真实机械臂上更复杂的操作任务研究奠定了基础。

参考文献

- [1] HUTCHINSON S, HAGER G D, CORKE P I. A Tutorial on Visual Servo Control [J]. IEEE Transactions on Robotics and Automation, 1996, 12(5): 651-670.
- [2] CHAUMETTE F, HUTCHINSON S. Visual Servo Control. I. Basic Approaches [J]. IEEE Robotics & Automation Magazine, 2006, 13(4): 82-90.
- [3] LAVALLE S M, KUFFNER J J. Randomized Kinodynamic Planning[J]. The International Journal of Robotics Research, 2001, 20(5): 378-400.
- [4] KARAMAN S, FRAZZOLI E. Sampling-Based Algorithms for Optimal Motion Planning[J]. The International Journal of Robotics Research, 2011, 30(7): 846-894.
- [5] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level Control through Deep Reinforcement Learning[J]. Nature, 2015, 518(7540): 529-533.
- [6] OpenAI, AKKAYA I, ANDRYCHOWICZ M, et al. Solving Rubik's Cube with a Robot Hand[C]//arXiv preprint arXiv:1910.07113. 2019.
- [7] ZENG A, SONG S, WELKER S, et al. Learning Synergies between Pushing and Grasping with Self-Supervised Deep Reinforcement Learning[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems. 2018: 4238-4245.
- [8] ANDRYCHOWICZ M, WOLSKI F, RAY A, et al. Hindsight Experience Replay [C]//Advances in Neural Information Processing Systems. 2017.
- [9] YU T, QUILLEN D, HE Z, et al. Meta-World: A Benchmark and Evaluation for Multi-Task and Meta Reinforcement Learning[C]//Conference on Robot Learning. 2020.
- [10] SUTTON R S, BARTO A G. Reinforcement Learning: An Introduction[M].

- 2nd ed. Cambridge, MA: MIT Press, 2018.
- [11] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms[C]//arXiv preprint arXiv:1707.06347. 2017.
 - [12] LILICRAP T P, HUNT J J, PRITZEL A, et al. Continuous Control with Deep Reinforcement Learning[C]//International Conference on Learning Representations. 2016.
 - [13] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[J]. Proceedings of the 35th International Conference on Machine Learning, 2018: 1861-1870.
 - [14] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
 - [15] LENZ I, LEE H, SAXENA A. Deep Learning for Detecting Robotic Grasps[J]. The International Journal of Robotics Research, 2015, 34(4-5): 705-724.
 - [16] MORRISON D, CORKE P, LEITNER J. Closing the Loop for Robotic Grasping: A Real-Time, Generative Grasp Synthesis Approach[J]. Robotics: Science and Systems, 2018.
 - [17] KUFFNER J J, LAVALLE S M. RRT-Connect: An Efficient Approach to Single-Query Path Planning[C]//Proceedings 2000 IEEE International Conference on Robotics and Automation. 2000: 995-1001.
 - [18] Van HASSELT H, GUEZ A, SILVER D. Deep Reinforcement Learning with Double Q-Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016.
 - [19] SCHAUL T, QUAN J, ANTONOGLOU I, et al. Prioritized Experience Replay [C]//International Conference on Learning Representations. 2016.
 - [20] KALASHNIKOV D, IRPAN A, PASTOR P, et al. QT-Opt: Scalable Deep Reinforcement Learning for Vision-Based Robotic Manipulation[C]//Conference on

- Robot Learning. 2018.
- [21] TODOROV E, EREZ T, TASSA Y. MuJoCo: A Physics Engine for Model-Based Control[C]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. 2012: 5026-5033.
 - [22] ZHU Y, WONG J, MANDLEKAR A, et al. robosuite: A Modular Simulation Framework and Benchmark for Robot Learning[C]//arXiv preprint arXiv:2009.12293. 2020.
 - [23] KHATIB O. A Unified Approach for Motion and Force Control of Robot Manipulators: The Operational Space Formulation[J]. IEEE Journal on Robotics and Automation, 1987, 3(1): 43-53.

致 谢

在本论文完成过程中，感谢指导教师邴振山老师在研究方向、实验设计和论文写作方面给予的指导。从论文选题、开题报告、系统设计到论文撰写，老师都给予了我悉心的指导和帮助。感谢姚相同博士、孟远博士、王博师兄、王宇轩同学和贾豪睿同学等所有在毕业论文中曾经帮助过我的师兄和同学。感谢开源社区提供的 MuJoCo、robosuite 和 Stable-Baselines3 等工具，使本文能够在较完整的机器人仿真平台上开展实验。

附录 A 缩略语说明

缩写	英文全称	中文含义
DQN	Deep Q-Network	深度 Q 网络
PPO	Proximal Policy Optimization	近端策略优化
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度
TD3	Twin Delayed Deep Deterministic Policy Gradient	双延迟深度确定性策略梯度
SAC	Soft Actor-Critic	软演员-评论家
GG-CNN	Generative Grasping Convolutional Neural Network	生成式抓取卷积神经网络
RRT	Rapidly-exploring Random Tree	快速探索随机树
OSC	Operational Space Control	操作空间控制
ROS2	Robot Operating System 2	第二代机器人操作系统